
Mustererkennung WiSe 12/13

Übung 6

Lutz Freitag, Sebastian Kürten

1 Aufgabe 1: PCA

1.1 Teil 1: PCA und Fisher

Wir machen die PCA einmal zu Beginn des Programms mit Hilfe der Trainingsdaten und transformieren sowohl Trainings- als auch Testdaten in den neuen Raum.

Dann trennen wir die Ziffern paarweise mit Hilfe von Fisher's Diskriminante und schauen nach, wie viele Datensätze korrekt klassifiziert wurden im Vergleich zur paarweisen Klassifizierung, die auf den Originaldaten ausgeführt wird. Wir testen mit 0, 1, ..., 6 weggelassenen Dimensionen und stellen fest:

- beim Weglassen von 0 Dimensionen bleibt die Erkennungsrate gleich
- beim Weglassen von einer Dimension wird die Erkennungsrate insgesamt besser
- beim Weglassen von mehr Dimension wird die Erkennungsrate allmählich schlechter

Der Vergleich erfolgt durch Subtrahieren der Matrizen in der die Anzahl der paarweise korrekt klassifizierten Datensätze erfasst sind.

1.1.1 Code

```
1 trainingData = load("-ascii", "pendigits-training.txt");
2 testingData = load("-ascii", "pendigits-testing.txt");
3
4 % Mittelwert der Daten berechnen
5 move = [mean(trainingData(:,1:end-1)) 0];
6 % und Daten zum Ursprung verschieben
7 trainingData = trainingData - repmat(move, size(trainingData, 1), 1);
8 testingData = testingData - repmat(move, size(testingData, 1), 1);
9
10 % features von den labels trennen
11 featuresTraining = trainingData(:,1:end-1);
12 labelsTraining = trainingData(:, end);
13
14 featuresTesting = testingData(:,1:end-1);
15 labelsTesting = testingData(:, end);
16
17 % compute mu and covariance matrix
18 [mu, cov] = gauss(featuresTraining);
19
20 % eigenvektoren und eigenwerte berechnen
21 % eigenvektoren stehen in den spalten
22 % die wichtigste komponente steht ganz rechts
23 [v, lambda] = eig(cov);
24
25
26
```

```

27 % Daten auf die Eigenvektoren projizieren
28 trainingPCA = [featuresTraining * v, labelsTraining];
29 testingPCA = [featuresTesting * v, labelsTesting];
30
31 % für je zwei Ziffern paarweise linear trennen mit
32 % Fisher's Diskriminante und die Anzahl der korrekt / falsch
33 % klassifizierten Daten merken
34 % —> hier mit den Originaldaten als Vergleichswert
35 [correctNormal, wrongNormal] = dofisher(trainingData, testingData);
36
37 % anzahl der zu entfernden Dimensionen
38 for remove = 0:6
39     % die unwichtigsten Hauptkomponenten wegwerfen
40     trainingPCAn = trainingPCA(:,remove + 1:end);
41     testingPCAn = testingPCA(:,remove + 1:end);
42
43     % Nochmal paarweise Fisher.
44     % —> hier mit den dimensionsreduzierten Daten nach PCA
45     [correctPCA, wrongPCA] = dofisher(trainingPCAn, testingPCAn);
46
47     % Anzahl der entfernten Dimensionen ausgeben
48     remove
49     % Differenz der korrekt klassifizieren Daten ausrechnen,
50     % als Vergleich zur Klassifizierung auf den Originaldaten
51     correctPCA - correctNormal
52     total = sum((correctPCA - correctNormal) (:))
53 end

```

1.1.2 Ausgabe

```

remove = 0
ans =

```

```

0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0
0 0 0 0 0 0 0 0 0 0

```

```

total = 0
remove = 1
ans =

```

```

0 0 0 0 0 -3 1 1 4 0
0 0 2 0 1 -1 0 0 0 1
0 2 0 0 0 1 0 0 0 0
-1 0 0 0 0 1 0 0 0 4
0 1 0 0 0 0 0 10 0 2
-3 -1 0 1 0 0 -2 3 -4 4
1 0 0 0 0 -2 0 2 0 0
1 0 0 0 10 3 2 0 0 -5
4 0 0 0 0 -4 0 0 0 0
0 1 0 4 2 4 0 -5 0 0

```

```
total = 42
remove = 2
ans =
```

0	0	0	0	0	-3	1	2	4	0
0	0	2	0	1	-3	0	4	0	1
0	2	0	0	0	1	0	1	0	0
-1	0	0	0	0	-2	0	-7	1	3
0	1	0	0	0	-4	0	2	0	2
-3	-3	0	-2	-4	0	-1	-2	-7	2
1	0	0	0	0	-1	0	2	1	0
2	4	1	-7	2	-2	2	0	0	-4
4	0	0	1	0	-7	1	0	0	0
0	1	0	3	2	2	0	-4	0	0

```
total = -8
remove = 3
ans =
```

0	0	1	0	0	1	0	4	4	1
0	0	-12	1	1	-5	-1	-4	0	1
4	-12	0	0	0	2	0	1	0	0
8	1	-1	0	-2	-1	0	-7	1	4
0	1	0	-2	0	-3	0	-2	0	2
1	-5	0	-1	-3	0	-7	0	-8	-2
0	-1	0	0	0	-7	0	2	1	0
4	-4	1	-7	-2	0	2	0	0	-4
4	0	0	1	0	-8	1	0	0	0
1	1	0	4	2	-2	0	-4	0	0

```
total = -54
remove = 4
ans =
```

0	0	1	0	0	0	0	4	2	1
0	0	-24	2	1	-6	2	-4	0	1
4	-24	0	0	0	2	0	1	0	0
8	2	-1	0	-1	-5	0	-29	2	-3
0	1	0	-1	0	-2	0	-5	0	2
0	-6	0	-5	-2	0	-5	1	-8	3
0	2	0	0	0	-5	0	2	1	0
4	-4	1	-29	-5	1	2	0	0	-10
2	0	0	2	0	-8	1	0	0	0
1	1	0	-3	2	3	0	-10	0	0

```
total = -140
remove = 5
ans =
```

0	0	-1	0	-1	1	1	8	3	1
0	0	-23	-1	1	-16	1	-4	0	0
7	-23	0	0	0	2	0	-1	0	0

8	-1	-1	0	-3	-11	-1	-29	2	4
-1	1	0	-3	0	-10	0	-4	0	2
1	-16	0	-11	-10	0	-6	6	-5	1
1	1	0	-1	0	-6	0	2	1	0
8	-4	-1	-29	-4	6	2	0	-1	-9
3	0	0	2	0	-5	1	-1	0	0
1	0	0	4	2	1	0	-9	0	0

```
total = -167
remove = 6
ans =
```

0	-1	-2	0	0	2	1	14	-3	1
-1	0	-27	-2	1	-14	1	0	-1	0
8	-27	0	0	0	2	0	-2	0	0
8	-2	-1	0	-2	-11	-1	-31	1	3
0	1	0	-2	0	-10	0	-7	0	2
2	-14	1	-11	-10	0	-6	3	-8	1
1	1	0	-1	0	-6	0	2	0	0
14	0	-2	-31	-7	3	2	0	-1	-18
-3	-1	0	1	0	-8	0	-1	0	0
1	0	0	3	2	1	0	-18	0	0

```
total = -210
```

1.2 Teil 2: PCA für die Ziffer 7 mit Darstellung

Hier haben wir die Hauptkomponenten für die Trainingsziffern mit Label 7 berechnet und diese grafisch dargestellt.

1.2.1 Code

```
1
2 % ausgabe der Hauptkomponente für die Ziffer 7
3 trainingData = load("-ascii", "pendigits-training.txt");
4 featuresDigit = trainingData(trainingData(:,17) == 7,:);
5 [muDigit, covDigit] = gauss(featuresDigit);
6 [vDigit, lambdaDigit] = eig(covDigit);
7 hold on;
8 for mainComponent = vDigit '
9     mainComponent
10     plot(mainComponent);
11 end
12 hold off;
13
14 print("ala.png")
15
16 pause
```

1.2.2 Ausgabe

siehe Abbildung 1




Figure 1: Darstellung der Hauptkomponenten für 7

2 Aufgabe 2: Perzeptron-Lernen

2.1 Code

2.1.1 a2.m

```
1 % zufälliger Vektor
2 w = rand([1, 4]) * 2 - 1;
3
4 % Trainingsdaten generieren
5 N = 10000;
6 X = 2 * rand([N, 3]) - 1;
7 X = [ones(N, 1) X];
8
9 % Labels bestimmen
10 y = (X * w') >= 0;
11
12 % mit Perzeptron lernen
13 pw = perceptron(X, y);
14
15 % Vorhersage mit dem gelernten w
16 prediction = (X * pw') >= 0;
17
18 % Vorhersage bewerten
19 nwrong = sum(prediction != y);
20 relativeError = nwrong / N;
21
22 w / norm(w)
23 pw / norm(pw)
```

2.1.2 perceptron.m

```
1 function bestW = perceptron(X, y)
2     len = size(X, 2);
3     w = rand([1, len]) * 2 - 1;
4     w = w / norm(w);
5
6     maxIterations = log10(size(X, 1)) * 50;
7     % Zähler für Iterationen als zusätzliches Abbruchkriterium
8     iteration = 1;
9     % beste Lösung merken
10    bestNWrong = Inf;
11    while true && iteration <= maxIterations
12        iteration++;
13        % vorhersage ausrechnen
14        prediction = X * w' >= 0;
15        % falsch klassifizierte daten finden
16        wrong = find(prediction != y);
17        % wenn alles richtig klassifiziert -> ende
18        nwrong = size(wrong, 1);
19        if nwrong < bestNWrong
20            bestNWrong = nwrong;
21            bestW = w;
22        end;
23        if nwrong == 0
24            break
25        end
26        % ansonsten, wähle zufällige einen falsch
27        % klassifizierten vektor aus
28        wk = randint(1,1, [1, nwrong]);
```

```

29         % den index des wk-ten falschen Vektors bestimmen
30         k = wrong(wk);
31
32         % hole den k-ten Vektor
33         x = X(k,:);
34         if y(k)
35             % x ist aus P
36             w = w + x;
37         else
38             % x ist aus N
39             w = w - x;
40         end
41     end
42 end

```

2.2 Ausgabe

Wir sehen hier die Fehlerrate, sowie den zu Beginn generierten Vektor und den gelernten Vektor, beide normiert zum Vergleich.

```

relativeError = 0.0019000
ans =

    -0.636667    0.450244   -0.035083    0.625064

ans =

    -0.642846    0.461415   -0.033900    0.610489

```

3 Aufgabe 3: Kantenerkennung

3.1 Code

3.1.1 a3.m

```
1 % alle möglichen 3x3 Bilder generieren
2 pixels = binary_permutations(9);
3
4 % Bilder labeln
5 ys = [];
6 for data = pixels '
7     ys(end + 1) = label(data);
8 end
9 ys = ys';
10
11 % Gewichte lernen
12 w = perceptron(pixels, ys);
13
14 % Bild laden
15 I = double(imread('lena.png'));
16 % nach schwarz-weiß konvertieren
17 BW = I > mean(I(:));
18
19 % Kantenbild berechnen
20 O = [];
21 [hei, wid] = size(BW);
22 % alle Teilbilder ansehen
23 for y = 2:hei-1
24     for x = 2:wid-1
25         % Teilbildmatrix holen
26         M = BW(y-1:y+1,x-1:x+1);
27         % in Vektor umwandeln
28         Mpixels = reshape(M, 1, 9);
29         % klassifizieren
30         O(y-1, x-1) = Mpixels * w';
31     end
32 end
33 % Bild abspeichern
34 imwrite(O, 'edges.png');
```

3.1.2 binarypermutations.m

```
1 function c = binary_permutations(k)
2     k = 9;
3     n = 2^k;
4     a = arrayfun(@(i) bitget(i, [1:k]), 0:n-1, 'UniformOutput', false);
5     b = cell2mat(a);
6     c = reshape(b, 9, n)';
7 end
```

3.1.3 label.m

```
1 function r = label(pixels)
2     r = pixels(5) == 0 && any(pixels);
3 end
```


3.2 Ausgabe



Figure 2: Eingabebild



Figure 3: Kantenbild

A Alte Funktionen

A.1 gauss.m

```
1 % Mittelwert und Kovarianzmatrix bestimmen
2 function [mu, cov] = gauss (samples)
3     % compute average
4     mu = mean(samples);
5
6     s = size(samples, 2);
7     % compute covariance matrix
8     cov = zeros(s, s);
9     for sample = samples'
10         cov += (sample - mu') * (sample' - mu);
11     end
12
13     cov = cov / size(samples, 1);
14 end;
```

A.2 bayes.m

```
1 function [probA, probB, class] = bayes(x, muA1, muB1, covA1, covB1)
2     % Warscheinlichkeiten ausrechnen
3     probA = 1 / (sqrt(2*pi) * covA1) * e^((-1/2) * (x-muA1)^2);
4     probB = 1 / (sqrt(2*pi) * covB1) * e^((-1/2) * (x-muB1)^2);
5     % Wähle die Warscheinlichere Klassennummer
6     class = 2;
7     if (probA > probB) % hier kommt die Asymmetrie her
8         class = 1;
9     end
10 end
```

A.3 dofisher.m

```
1 function correct, wrong = dofisher(trainingData, testingData)
2     mus = {};
3     covariances = {};
4
5     for digit = 0:9
6         % select all samples labeled with 'digit'
7         samples = trainingData(trainingData(:,end) == digit, :)(:,1:end-1);
8         % compute mu and covariance matrix
9         [mu, cov] = gauss(samples);
10        % store for later usage
11        mus{digit + 1} = mu;
12        covariances{digit + 1} = cov;
13    end
14
15    % fisher für zwei klassen ausführen
16    %[ncorrect, nwrong] = fisher(mus, covariances, testingData, 0, 1)
17
18    % fisher für alle paare von zwei klassen ausführen
19    split_long_rows(false);
20    output_max_field_width(2);
21    n = 9;
22    [correct, wrong] = arrayfun(@(i,j) fisher(mus, covariances, ...
        testingData, i, j), \
```

```

23         repmat([0:n], n+1, 1), repmat([0:n], n+1, 1)');
24 end

```

A.4 fisher.m

```

1 function [ncorrect, nwrong] = fisher(mus, covariances, testingData, ...
   digitA, digitB)
2 % ignoriere den Fall, dass die Funktion mit digitA = digitB ...
   aufgerufen wird.
3 if (digitA == digitB)
4     ncorrect = 0;
5     nwrong = 0;
6     return;
7 end;
8 % Eingabe sind Zeilenvektoren!
9 testA = testingData(testingData(:,end) == digitA,:)(:,1:end - 1);
10 testB = testingData(testingData(:,end) == digitB,:)(:,1:end - 1);
11 % mus holen
12 muA = mus{digitA + 1};
13 muB = mus{digitB + 1};
14 % Kovarianzen holen
15 covA = covariances{digitA + 1};
16 covB = covariances{digitB + 1};
17 % Projektionsrichtung ausrechnen
18 a = (muA - muB) * (covA + covB)^(-1);
19 % eindimensionale Gaussverteilung bestimmen
20 muA1 = a * muA';
21 muB1 = a * muB';
22 covA1 = a*covA*a';
23 covB1 = a*covB*a';
24 % Projiziere Testdaten auf a
25 pA = testA * a';
26 pB = testB * a';
27 % Wahrscheinlichkeiten nach Bayes
28 [probsA1, probsB1, classes1] = arrayfun(@(x) \
   bayes(x, muA1, muB1, covA1, covB1), pA);
29 [probsA2, probsB2, classes2] = arrayfun(@(x) \
   bayes(x, muA1, muB1, covA1, covB1), pB);
30 ncorrect = sum(classes1 == 1) + sum(classes2 == 2);
31 nwrong = sum(classes1 == 2) + sum(classes2 == 1);
32
33
34 end

```